

Cómo realizar el proyecto completo

Guía única de principio a fin del proyecto «Análisis del Impacto de Hábitos de Vida y Factores Demográficos en los Gastos Médicos de Personas Aseguradas».

Documento autónomo y didáctico. Explica la propuesta entera, el código, las fórmulas y las palabras técnicas de forma sencilla, para que **cualquier colaborador del repositorio —o una IA— pueda ejecutar el proyecto sin conocimientos previos avanzados**. Todo lo técnico está contrastado con fuentes científicas citadas en APA al final. Para profundizar en una fase concreta, existen documentos dedicados (`research_phase2...7`) en esta misma carpeta.

0. Cómo usar esta guía

Léela en orden si empiezas de cero. Si ya sabes tu fase, ve directo a su sección, pero **revisa siempre el «Cableado» (dependencias)** para saber qué necesitas de tus compañeros y qué debes entregarles.

Convenciones:

Marca	Significado
 Verificado	Dato comprobado con los datos o con la literatura.
 Cableado	Dependencia entre fases: qué recibe y qué entrega.
 Consejo	Buena práctica que mejora la calificación.
 Advertencia	Error común o límite científico que hay que declarar.

1. Glosario: las palabras técnicas, en fácil

Si una palabra te frena, búscala aquí antes de seguir.

Término	Explicación sencilla
Minería de datos	Extraer información útil y patrones de grandes conjuntos de datos.

Dataset	El conjunto de datos: una tabla con filas (personas) y columnas (variables).
Variable dependiente (Y)	Lo que queremos explicar o predecir. Aquí: charges (el gasto médico).
Variable independiente (X)	Los factores que usamos para explicar Y (edad, IMC, fumar...).
Aprendizaje supervisado	Entrenar con datos que ya tienen la respuesta, para predecir. La regresión es supervisada.
Aprendizaje no supervisado	Buscar grupos o estructura sin respuesta previa. El clustering es no supervisado.
EDA	Análisis Exploratorio de Datos: «conocer» los datos con estadísticas y gráficas antes de modelar.
Correlación	Qué tan asociadas están dos variables, en un número de -1 a $+1$.
Regresión lineal	Una ecuación (recta) que estima Y a partir de las X y mide cuánto pesa cada factor.
Clustering	Agrupar registros parecidos entre sí (perfiles).
Coeficiente	El número que multiplica a una variable en la ecuación; dice cuánto cambia Y por unidad de esa X.
Outlier (atípico)	Un valor muy alejado del resto.
Sesgo / asimetría (skew)	Cuando una distribución tiene una cola larga hacia un lado.
Escalar / estandarizar	Poner variables de escalas distintas en una escala común para compararlas.
Centroide	El punto central de un grupo en clustering.
p-value	Probabilidad de ver un efecto por azar; si es <0.05 , el efecto se

considera significativo.

R^2	Qué proporción de la variación de Y explica el modelo (0 a 1).
CRISP-DM	Metodología estándar de minería de datos en 6 fases.
DataFrame	La tabla de datos dentro de Python (librería pandas).

2. La propuesta: qué problema resolvemos

Una **aseguradora médica** quiere fijar primas (precios de póliza) justas: cobrar según el riesgo real de cada persona. Para eso necesita saber *qué factores elevan el gasto médico*. La pregunta de investigación es:

«¿Qué hábitos de vida y factores demográficos se asocian con cargos médicos más altos, y cuánto pesa cada uno?»

- **Variable dependiente (Y):** charges — gasto médico anual en dólares.
- **Variables independientes (X):** age (edad), sex (sexo), bmi (IMC), children (dependientes), smoker (fumador), region (región).

Respaldo del mundo real (verificado con literatura). El tabaquismo representa ~11.7% de todo el gasto sanitario personal de EE.UU. (~\$226.7 mil millones en 2014; Xu et al., 2015) y la obesidad añade ~\$1 861–2 505 de gasto por adulto/año (Cawley & Meyerhoefer, 2012). Es decir: el problema que estudiamos es real y económicamente enorme.

Honestidad sobre los datos. El dataset `insurance.csv` es **simulado** por Brett Lantz sobre demografía del Census de EE.UU. (Lantz, 2019); no son pacientes reales. Por eso el proyecto es *didáctico*: las técnicas y las tendencias son válidas, pero las cifras exactas no sirven para decisiones clínicas o de tarificación reales. Declararlo demuestra madurez.

3. Los datos: descripción

Fuente: Kaggle, *Medical Cost Personal Dataset* (originado en Lantz, 2019). **7 variables, 1 338 registros** (1 337 tras quitar 1 duplicado), **sin valores nulos**. Cada fila es una persona asegurada.

Variable	Tipo	Descripción
age	Numérica	Edad (18–64 años).
sex	Categórica	Sexo: female / male.
bmi	Numérica	Índice de masa corporal (16–53).
children	Numérica	Número de dependientes (0–5).
smoker	Categórica	Fumador: yes / no.
region	Categórica	Región de EE.UU. (4 valores).
charges	Numérica (Y)	Gasto médico anual en USD (\$1 122–\$63 770).

4. El plan: la metodología CRISP-DM y los 7 días

Trabajamos con **CRISP-DM** (Chapman et al., 2000), el proceso estándar de minería de datos. Sus 6 fases encajan con nuestro plan de 7 días:

Fase CRISP-DM	Día / notebook	Qué se hace
Comprensión del negocio	—	Definir el problema y las variables (§2).
Comprensión de los datos	Día 1–2 · 00_setup, 01_edu	Cargar, describir y explorar.
Preparación de los datos	Día 2 · 01_edu	Limpiar y codificar.
Modelado	Días 3–5 · 02_correlacion, 03_regresion, 04_clustering	Correlación, regresión, clustering.
Evaluación	Día 6	Interpretar y sacar conclusiones.

Nota: el temario también menciona SEMMA (SAS); es similar pero más centrada en el modelado. CRISP-DM es más completa porque incluye negocio y despliegue.

5. Preparar el entorno (una sola vez)

```
python3 -m venv .venv          # crea un entorno aislado
source .venv/bin/activate      # actívalo (Windows: .venv\Scripts\activate)
pip install -r requirements.txt # instala pandas, seaborn, sklearn, statsmodels...
jupyter notebook               # abre los cuadernos
```

Herramientas y para qué sirven: **pandas/NumPy** (manejo de datos), **matplotlib/seaborn** (gráficas), **scikit-learn** (modelos y métricas), **statsmodels** (regresión con p-values), **LibreOffice** (generar PDFs, vía `scripts/generate_document.py`).

6. Estadística que necesitas (con fórmulas explicadas)

MEDIA (promedio)

$$\bar{x} = (1 / n) \cdot \sum x_i$$

Suma de todos los valores dividida entre cuántos hay. Es el centro típico, pero la **arrastran** los extremos.

DESVIACIÓN ESTÁNDAR

$$s = \sqrt{ (1 / (n-1)) \cdot \sum (x_i - \bar{x})^2 }$$

Mide la dispersión alrededor de la media. Se dividen entre $n-1$ (corrección de Bessel) para no subestimarla en una muestra.

La **mediana** (valor central al ordenar) resiste los atípicos mejor que la media. En charges, media (\$13 279) > mediana (\$9 386): señal de **sesgo a la derecha**.

7. Fase Día 2 — Análisis Exploratorio (EDA)

Cableado. Recibe el dataset limpio del Día 1. Entrega a Días 3–5 el conocimiento de outliers y sesgo, y guarda las gráficas en reports/figures/ para el Día 7.

7.1 Detección de outliers (regla IQR de Tukey)

VALLAS DE TUKEY

$$\text{IQR} = Q_3 - Q_1 ; \text{inferior} = Q_1 - 1.5 \cdot \text{IQR} ; \text{superior} = Q_3 + 1.5 \cdot \text{IQR}$$

Q_1 y Q_3 son los cuartiles (25% y 75%). El IQR es el ancho del 50% central. Lo que quede más allá de $1.5 \cdot \text{IQR}$ se marca como atípico (Tukey, 1977).

```
sns.boxplot(x=df["charges"]); plt.savefig("../reports/figures/box_charges.png",
bbox_inches="tight")
```

Cómo leer un boxplot: la caja va de Q_1 a Q_3 , la línea es la mediana, los bigotes llegan a las vallas y los puntos sueltos son outliers.

Decisión: en este dataset los outliers de charges/bmi son casos reales (no errores), así que **se conservan:** son justo los perfiles de riesgo que buscamos.

7.2 Distribuciones y sesgo

```
for c in ["age", "bmi", "children", "charges"]:
    sns.histplot(df[c], kde=True); plt.title(c);
    plt.savefig(f"../reports/figures/hist_{c}.png", bbox_inches="tight"); plt.show()
print(df.select_dtypes("number").skew())
```

charges está fuertemente sesgada a la derecha (skew $\approx +1.5$); bmi casi simétrica; age casi uniforme.

7.3 Categóricas y relaciones

```
for c in ["sex","smoker","region"]: sns.countplot(x=c, data=df); plt.show()
sns.scatterplot(x="bmi", y="charges", hue="smoker", data=df) # color = fumador
```

■ Solo ~20% son fumadores (274/1337). En bmi vs charges aparece una **interacción**
clave: entre fumadores, más IMC dispara el gasto; entre no fumadores casi no cambia.

8. Fase Día 3 — Correlación

■ **Cableado.** Usa `df_numerico` (categorías ya convertidas a número). Entrega a la regresión qué variables se asocian más con charges y avisa de multicolinealidad.

CORRELACIÓN DE PEARSON (r) — relación lineal

$$r = [\Sigma (x_i - \bar{x})(y_i - \bar{y})] / \sqrt{ \Sigma(x_i - \bar{x})^2 \cdot \Sigma(y_i - \bar{y})^2 }$$

El numerador (covarianza) mide si x e y suben juntas; el denominador normaliza para dejar r entre -1 y +1. Pearson mide relación **lineal** y es sensible a outliers. Como charges es sesgada, conviene reportar también **Spearman** (usa rangos, más robusto).

```
corr = df_numerico.corr(method="pearson")
sns.heatmap(corr, annot=True, cmap="coolwarm", fmt=".2f", vmin=-1, vmax=1)
print(corr["charges"].sort_values(ascending=False))
```

Cómo leer el heatmap: rojo $\approx +1$ (suben juntas), azul ≈ -1 (opuestas), blanco ≈ 0 . Mira la fila de charges.

Variable vs charges	Pearson r	Lectura
smoker	+0.79	Fuerte — domina
age	+0.30	Débil-moderada
bmi	+0.20	Débil (lineal)

children	+0.07	Despreciable
sex	-0.06	Despreciable

Correlación ≠ causalidad. La correlación sugiere, no prueba causa. Redacta «asociado con», no «causa» (salvo que cites evidencia causal como Xu et al., 2015).

9. Fase Día 4 — Regresión lineal (técnica principal)

Cableado. Usa `df_numerico` con 8 columnas X (incluye `region_northwest/southeast/southwest` de `get_dummies(drop_first=True)`; la región omitida *northeast* es la referencia). Entrega R^2 , coeficientes y p-values al Día 6/7.

MODELO MÚLTIPLE Y SOLUCIÓN OLS

$$\hat{y} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon \longrightarrow \beta = (X^T X)^{-1} X^T y$$

Cada β_j dice cuántos dólares cambia el gasto por una unidad de esa variable, con lo demás constante. Se obtienen por **mínimos cuadrados (OLS)**: minimizan $\sum (y_i - \hat{y}_i)^2$. No hay que calcularlo a mano; lo hace la librería.

```
import statsmodels.api as sm
X = sm.add_constant(df_numerico.drop(columns="charges"))
y = df_numerico["charges"]
modelo = sm.OLS(y, X).fit()
print(modelo.summary())      # R², coeficientes y p-values de un golpe
```

R^2 — qué tan bueno es el modelo

$$R^2 = 1 - [\sum (y_i - \hat{y}_i)^2] / [\sum (y_i - \bar{y})^2]$$

Proporción de la variación del gasto que el modelo explica (0 a 1). El **p-value** de cada variable dice si su efecto es significativo ($p < 0.05$).

Resultado verificado con estudios replicados: $R^2 \approx 0.75\text{--}0.76$; coeficiente de smoker $\approx +\$23\,800$ (23 848 / 23 811 en la literatura); age, bmi y smoker son muy significativas.

Mejora recomendada: por el sesgo, ajusta un modelo con $y = \text{np.log}(\text{charges})$; estabiliza la varianza y suele mejorar (Feng et al., 2014). Recuerda que los coeficientes en log se interpretan como % de cambio.

10. Fase Día 5 — Clustering K-means

Cableado. Usa las numéricas crudas age, bmi, charges (no las dummies). Es paralela a la regresión: una segmenta, la otra predice. Entrega los perfiles de riesgo al Día 6/7.

INERCIA (lo que K-means minimiza)

$$\text{WCSS} = \sum_k \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

K-means arma **K** grupos y coloca un **centroide** (μ_k) en el centro de cada uno; asigna cada punto al centroide más cercano y repite. Minimiza la suma de distancias al cuadrado dentro de los grupos (Lloyd, 1982).

Escala obligatoria. K-means usa distancias; sin escalar, charges (hasta 64 000) aplastaría a age y bmi. Estandariza primero.

ESTANDARIZACIÓN Z-SCORE (StandardScaler)

$$z = (x - \mu) / \sigma$$

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
X = StandardScaler().fit_transform(df[["age","bmi","charges"]]) # media 0, desv 1
inercias = [KMeans(n_clusters=k, random_state=42, n_init=10).fit(X).inertia_ for k
in range(1,11)]
plt.plot(range(1,11), inercias, marker="o"); plt.title("Método del codo");
plt.show()
```

Método del codo: la inercia baja al subir K; se elige el «codo» (donde deja de bajar mucho). Suele salir K=3 o 4. Valida con el **coeficiente de silueta** (Rousseeuw, 1987), que va de -1 a +1 y es más fiable si el codo no es claro.

```
km = KMeans(n_clusters=3, random_state=42, n_init=10)
df["cluster"] = km.fit_predict(X)
sns.scatterplot(x="bmi", y="charges", hue="cluster", data=df)
print(df.groupby("cluster")[["age", "bmi", "charges"]].mean()) # perfil de cada grupo
```

■ **Interpreta y nombra** cada cluster (ej. «bajo riesgo», «IMC alto costo moderado», «costo elevado»). Un grupo sin nombre no comunica.

11. Fase Día 6 — Interpretación y conclusiones

Consolida los 4 notebooks en una historia con la estructura **Hallazgo** → **Evidencia** → **Significado**. La fuerza está en la *triangulación*: que correlación, regresión y clustering apunten al mismo factor.

■ **Conclusión central:** fumar es el factor dominante ($r=+0.79$; +\$23 800 con $p<0.05$; coincide con el cluster de alto costo). Edad e IMC son secundarios; sexo y región, débiles.

■ **Limitaciones a declarar:** datos simulados; solo EE.UU.; faltan variables (historial médico); correlación≠causalidad; posible heterocedasticidad (mitigable con log).

Recomendaciones: primas ajustadas por condición de fumador; programas de cesación de tabaco y control de IMC; segmentación por perfiles; recolectar más variables a futuro.

12. Fase Día 7 — Documento PDF y presentación

PDF (registro completo): portada institucional, introducción, desarrollo (selección, descripción, preparación, análisis con capturas, interpretación), conclusión, referencias.

Presentación (solo resultados interpretados): aplica storytelling con datos (Knafllic, 2015) — un mensaje por diapositiva, sin desorden, resaltar solo el dato clave, estructura Setup → Insight → Action. Slides sugeridas: portada, objetivo, hallazgo de correlación, regresión, perfiles/clusters, conclusiones.

```
python scripts/generate_document.py reporte_final.html pdf # genera el PDF en docs/generated_docs/
```

13. Mapa a la rúbrica (dónde están los puntos)

Criterio	Peso	Fase que lo cubre
Selección y descripción de datos	20%	§2–3 (Días 1–2)
Preparación de los datos	20%	§7 (Día 2)
Análisis de datos	30%	§8–10 (Días 3–5)
Interpretación de resultados	20%	§11 (Día 6)
Presentación y comunicación	10%	§12 (Día 7)

El **30% del Análisis** es el de mayor peso: prioriza que regresión y correlación estén bien hechas y *justificadas*.

14. Si eres una IA colaborando

1. Activa el entorno e instala dependencias.
2. Sigue las 6 fases CRISP-DM en orden; respeta el «Cableado» de cada fase.
3. Reporta métricas en el conjunto de *prueba*, no solo en entrenamiento.
4. Sé explícito con las limitaciones (datos simulados, causalidad).
5. Genera entregables con `scripts/generate_document.py` hacia `docs/generated_docs/`.

15. Apéndice: todas las fórmulas juntas

Fórmula	Para qué sirve
$\bar{x} = (1/n) \cdot \sum x_i$	Media.

$s = \sqrt{[(1/(n-1)) \cdot \Sigma(x_i - \bar{x})^2]}$	Desviación estándar (dispersión).
$Q_1 - 1.5 \cdot IQR ; Q_3 + 1.5 \cdot IQR$	Vallas de outliers (Tukey).
$r = \frac{\Sigma(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{[\Sigma(x_i - \bar{x})^2 \cdot \Sigma(y_i - \bar{y})^2]}}$	Correlación de Pearson (lineal).
$\rho = 1 - 6\Sigma d_i^2/[n(n^2-1)]$	Correlación de Spearman (monótona).
$\hat{y} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$	Modelo de regresión múltiple.
$\beta = (X^T X)^{-1} X^T y$	Solución OLS de los coeficientes.
$R^2 = 1 - \Sigma(y_i - \hat{y}_i)^2 / \Sigma(y_i - \bar{y})^2$	Bondad de ajuste del modelo.
$WCSS = \Sigma_k \Sigma \ x_i - \mu_k\ ^2$	Inercia que minimiza K-means.
$z = (x - \mu) / \sigma$	Estandarización (escalar variables).

Referencias (APA 7)

- Cawley, J., & Meyerhoefer, C. (2012). The medical care costs of obesity: An instrumental variables approach. *Journal of Health Economics*, 31(1), 219–230. <https://doi.org/10.1016/j.jhealeco.2011.10.003>
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- Feng, C., Wang, H., Lu, N., Chen, T., He, H., Lu, Y., & Tu, X. M. (2014). Log-transformation and its implications for data analysis. *Shanghai Archives of Psychiatry*, 26(2), 105–109. <https://doi.org/10.3969/j.issn.1002-0829.2014.02.009>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning* (2nd ed.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>
- Knafllic, C. N. (2015). *Storytelling with data: A data visualization guide for business professionals*. Wiley.
- Lantz, B. (2019). *Machine learning with R* (3rd ed.). Packt Publishing.
- Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129–137. <https://doi.org/10.1109/TIT.1982.1056489>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)

Schober, P., Boer, C., & Schwarte, L. A. (2018). Correlation coefficients: Appropriate use and interpretation. *Anesthesia & Analgesia*, 126(5), 1763–1768. <https://doi.org/10.1213/ANE.0000000000002864>

Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92–96. <https://doi.org/10.25080/Majora-92bf1922-011>

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Xu, X., Bishop, E. E., Kennedy, S. M., Simpson, S. A., & Pechacek, T. F. (2015). Annual healthcare spending attributable to cigarette smoking: An update. *American Journal of Preventive Medicine*, 48(3), 326–333. <https://doi.org/10.1016/j.amepre.2014.10.012>