

Técnicas de minería de datos, explicadas con fórmulas

Del análisis exploratorio a la regresión lineal: qué es cada técnica, cuál es su fórmula, qué significa cada símbolo y cómo se aplica al dataset de gastos médicos.

Cada fórmula se presenta, se traduce a español llano y se acompaña de un ejemplo con los números reales del proyecto. Las expresiones fueron contrastadas con fuentes estadísticas (ver Referencias). **Convención:** n = número de observaciones; $\bar{x}$ = media de x ; $\hat{y}$ = valor predicho; y_i = valor real de la observación i .

1. ¿Dónde encaja este proyecto?

La minería de datos usa tres grandes enfoques de aprendizaje automático:

Enfoque	Idea	Ejemplo
Supervisado	Aprender de datos <i>con respuesta conocida</i> para predecir.	Predecir charges a partir de edad, IMC, fumador...
No supervisado	Encontrar grupos/estructura <i>sin respuesta</i> .	Agrupar asegurados por perfil de riesgo (K-means).
Por refuerzo	Aprender por ensayo y error con recompensas.	(No aplica a este proyecto.)

Como la variable objetivo charges es **numérica y conocida**, este es un problema **supervisado de regresión**. La técnica principal es la **regresión lineal**, apoyada por **análisis de correlación** y **visualización**.

2. Estadística descriptiva (la base del EDA)

Antes de modelar hay que *describir* los datos. Tres medidas esenciales:

MEDIA (promedio)

$$\bar{x} = (x_1 + x_2 + \dots + x_n) / n = (1 / n) \cdot \sum x_i$$

Suma todos los valores y divide entre cuántos hay. Es el «centro» típico, pero **se deja arrastrar por valores extremos**.

MEDIANA

valor central al ordenar los datos de menor a mayor

Divide la muestra en dos mitades. A diferencia de la media, **resiste los atípicos**. En charges, la media (~\$13 279) es bastante mayor que la mediana (~\$9 386): señal de una distribución **sesgada a la derecha** por unos pocos gastos altísimos.

DESVIACIÓN ESTÁNDAR

$$s = \sqrt{[(1 / (n - 1)) \cdot \sum (x_i - \bar{x})^2]}$$

Mide cuánto se «dispersan» los datos alrededor de la media. Se elevan al cuadrado las distancias (para que no se cancelen los signos), se promedian y se saca la raíz para volver a las unidades originales. Se divide entre $n-1$ (no n) por la *corrección de Bessel*, que evita subestimar la dispersión al trabajar con una muestra.

Verificado en el dataset: charges tiene media ≈ \$13 279, mediana ≈ \$9 386,

desviación ≈ \$12 110, mínimo ≈ \$1 122 y máximo ≈ \$63 770. La gran distancia media–

mediana confirma el sesgo.

3. Análisis de correlación

La **correlación** mide qué tan asociadas están dos variables. El coeficiente va de **-1 a +1**: +1

asociación positiva perfecta, -1 negativa perfecta, 0 sin asociación lineal.

3.1 Correlación de Pearson (relación lineal)

COEFICIENTE DE PEARSON (r)

$$r = [\Sigma (x_i - \bar{x})(y_i - \bar{y})] / \sqrt{ \Sigma(x_i - \bar{x})^2 \cdot \Sigma(y_i - \bar{y})^2 }$$

En español: el numerador es la *covarianza* (¿cuando x sube, y sube?); el denominador normaliza dividiendo por las dispersiones de cada variable, para que el resultado quede acotado entre -1 y 1. Pearson asume que la relación es **lineal**, que las variables son de escala de intervalo/razón y aproximadamente **normales**, y es **sensible a valores atípicos**.

3.2 Correlación de Spearman (relación monótona)

Cuando la relación no es lineal (pero sí consistente en dirección) o hay atípicos y sesgo, se usa **Spearman**, que aplica Pearson *sobre los rangos* (posiciones ordenadas) en vez de los valores crudos.

COEFICIENTE DE SPEARMAN (ρ), sin empates

$$\rho = 1 - [6 \cdot \Sigma d_i^2] / [n \cdot (n^2 - 1)]$$

Donde d_i = diferencia de rangos de la observación i . Al basarse en rangos, Spearman capta relaciones **monótonas** aunque no sean rectas y es **más robusto a atípicos**.

	Pearson	Spearman
Detecta	Relación lineal	Relación monótona (no necesariamente lineal)
Datos	Numéricos, ~normales	Numéricos u ordinales, sesgados OK

Atípicos

Sensible

Robusto

Recomendación para este proyecto. Como charges está sesgada y tiene atípicos, conviene reportar **ambas** correlaciones. Si difieren mucho, es señal de no-linealidad (justo lo que ocurre con IMC entre fumadores).

3.3 Resultado aplicado (calculado sobre el dataset)

Variable vs charges	Pearson (r)	Lectura
smoker (fumador)	+0.79	Asociación fuerte: el factor dominante.
age (edad)	+0.30	Asociación moderada-baja.
bmi (IMC)	+0.20	Débil de forma lineal (pero clave al interactuar con fumar).
children (hijos)	+0.07	Casi nula.
sex (sexo)	-0.06	Prácticamente irrelevante.

Comprobación cruzada. El gasto medio de un **fumador** $\approx$ **\$32 050** frente a **\$8 441** de un no fumador: una diferencia de $\sim 3.8\times$. El número coincide con la correlación alta y con la evidencia médica externa (ver §7).

Advertencia científica: correlación $\neq$ causalidad. Una correlación alta no prueba que una variable *cause* la otra; podría haber un tercer factor. La correlación *sugiere* relaciones; la *regresión* y el conocimiento del dominio las contextualizan.

4. Preparar variables categóricas

Los modelos numéricos no entienden texto («yes», «southeast»). Hay que codificar:

Método	Cómo	Cuándo
Binaria / mapeo	smoker $\rightarrow$ {no:0, yes:1}	Variables de 2 categorías (sex,

smoker).

One-hot (dummies)	<code>pd.get_dummies(df, columns=["region"])</code>	Variables nominales de 3+ categorías (region).
-------------------	---	--

La «trampa de las variables dummy». Si una variable tiene k categorías y creas k columnas dummy más el intercepto, se produce **multicolinealidad perfecta** (una columna es combinación exacta de las otras) y la regresión falla o se vuelve inestable. La solución es soltar una categoría de referencia: `drop_first=True`, dejando $k-1$ columnas. Cada coeficiente se interpreta entonces *respecto* a la categoría omitida.

5. Regresión lineal

5.1 Regresión lineal simple

Modela la variable dependiente y como una recta en función de una sola x :

MODELO SIMPLE

$$\hat{y} = \beta_0 + \beta_1 \cdot x$$

β_0 (intercepto) = valor esperado de y cuando $x=0$. β_1 (pendiente) = cuánto cambia y por cada unidad que sube x . El «sombrero» en $\hat{y}$ indica que es una *predicción*, no el valor real.

5.2 ¿Cómo se eligen β_0 y β_1 ? Mínimos cuadrados (OLS)

Se busca la recta que **minimiza la suma de los errores al cuadrado** (la distancia vertical entre cada punto real y la recta):

CRITERIO DE MÍNIMOS CUADRADOS

$$\min \sum (y_i - \hat{y}_i)^2 = \min \sum (y_i - \beta_0 - \beta_1 \cdot x_i)^2$$

Resolver ese mínimo (derivando e igualando a cero) da fórmulas cerradas:

ESTIMADORES OLS (caso simple)

$$\beta_1 = [\sum (x_i - \bar{x})(y_i - \bar{y})] / [\sum (x_i - \bar{x})^2] ; \quad \beta_0 = \bar{y} - \beta_1 \cdot \bar{x}$$

5.3 Regresión lineal múltiple

Con varias variables independientes (edad, IMC, fumador, hijos, región):

MODELO MÚLTIPLE

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

En forma matricial, la solución OLS es compacta y elegante:

SOLUCIÓN MATRICIAL (ecuaciones normales)

$$\beta = (X^T X)^{-1} X^T y$$

Donde X es la matriz de datos (una fila por persona, una columna por variable + una de unos para el intercepto), y el vector de gastos y y β el vector de coeficientes. Cada β_j se interpreta como: «manteniendo las demás variables constantes, subir x_j en una unidad cambia el gasto en β_j dólares».

Interpretación esperada. En este dataset, el coeficiente de smoker ronda los **+\$23 000**

−24 000: ser fumador, a igualdad de edad/IMC/etc., se asocia con ~\$23 000 más de

gasto anual. Es, por mucho, el mayor efecto.

5.4 Supuestos del modelo (teorema de Gauss-Markov)

OLS da el «Mejor Estimador Lineal Insesgado» (BLUE) si se cumplen:

Supuesto

Qué significa

Linealidad	La relación entre X y y es lineal en los parámetros.
Muestreo aleatorio	Las observaciones se tomaron al azar de la población.
No multicolinealidad perfecta	Ninguna variable X es combinación exacta de otras.
Exogeneidad (media cero del error)	El error no se correlaciona con las X : $E[\epsilon X]=0$.
Homocedasticidad	La varianza del error es constante para todo valor de X .

Limitación real de este proyecto. Como *charges* está muy sesgada, es habitual que se viole la **homocedasticidad** y la normalidad de los residuos. Una mejora frecuente es modelar **log(charges)** en vez de *charges*. Reportar esta limitación suma puntos en el criterio de interpretación.

6. Evaluar el modelo

¿Qué tan bueno es? Se compara lo predicho ($\hat{y}$) contra lo real (y).

COEFICIENTE DE DETERMINACIÓN (R^2)

$$R^2 = 1 - [\sum (y_i - \hat{y}_i)^2] / [\sum (y_i - \bar{y})^2]$$

Proporción de la variación de y que el modelo **logra explicar**, de 0 a 1. $R^2=0.75 \Rightarrow$ el modelo explica el 75% de la variabilidad del gasto. El numerador es el error del modelo; el denominador, el error de simplemente usar la media.

R^2 AJUSTADO

$$R^2_{aj} = 1 - (1 - R^2) \cdot (n - 1) / (n - p - 1)$$

Penaliza agregar variables inútiles (p = número de predictores). Sube *solo* si la variable nueva

aporta más de lo que aportaría el azar. Es el más honesto para comparar modelos con distinto número de variables.

RAÍZ DEL ERROR CUADRÁTICO MEDIO (RMSE)

$$\text{RMSE} = \sqrt{\left(1 / n \right) \cdot \sum \left(y_i - \hat{y}_i \right)^2}$$

Error típico de predicción, **en las mismas unidades** que y (dólares). Al elevar al cuadrado, castiga más los errores grandes. $\text{RMSE} = \$6\,000 \Rightarrow$ el modelo se equivoca, en promedio, unos \$6 000.

ERROR ABSOLUTO MEDIO (MAE)

$$\text{MAE} = \left(1 / n \right) \cdot \sum \left| y_i - \hat{y}_i \right|$$

Promedio de los errores en valor absoluto. Más fácil de interpretar y **más robusto a atípicos** que el RMSE. Si $\text{RMSE} \gg \text{MAE}$, hay errores grandes puntuales (típico con datos sesgados).

Referencia. La regresión lineal múltiple estándar sobre este dataset suele alcanzar $R^2 \approx$

0.75. El gran salto de calidad viene de incluir `smoker` y su interacción con `bmi`.

6.1 No te engañes: entrenamiento vs prueba

Un modelo puede memorizar los datos de entrenamiento y fallar con datos nuevos. Por eso se separan:

- **Train/test split:** entrenar con ~80% y evaluar con el 20% no visto.
- **Validación cruzada (k-fold):** repetir el reparto k veces y promediar; estima mejor el desempeño real.

Problema

Síntoma

Idea

Overfitting (sobreajuste) R^2 alto en train, bajo en test

El modelo memoriza el ruido;

simplifícalo.

Underfitting (subajuste) R^2 bajo en ambos

El modelo es demasiado simple;
añade variables/complejidad.

7. Contexto científico: ¿tiene sentido el resultado?

Un buen análisis contrasta sus hallazgos con la literatura. La señal «fumar → mucho más gasto» está respaldada por evidencia revisada por pares:

- El tabaquismo representó cerca del **11.7% de todo el gasto sanitario personal de EE.UU.** (~\$226.7 mil millones en 2014).
- La obesidad se asocia con **+\$1 861 a +\$2 505 de gasto médico por adulto/año** (revisiones sistemáticas y meta-análisis).

Honestidad sobre los datos. El dataset `insurance.csv` es **simulado** (generado por Brett Lantz sobre demografía del Census de EE.UU.), no son historiales médicos reales. Por eso las conclusiones son **didácticas**: ilustran técnicas y coinciden con tendencias reales, pero no deben usarse para decisiones clínicas o de tarificación reales. Declararlo es parte del rigor.

Referencias

1. James, G., Witten, D., Hastie, T. & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2ª ed.). Springer. statlearning.com (PDF gratuito).
2. Schober, P. et al. (2018). «Correlation Coefficients: Appropriate Use and Interpretation». *Anesthesia & Analgesia* 126(5). [enlace](#)
3. Gauss–Markov theorem. *Wikipedia / Statistics By Jim*. statisticsbyjim.com
4. Lantz, B. (2019). *Machine Learning with R* (3ª ed.), Packt — fuente original del dataset. Espejo de datos: github.com/stedy
5. Xu, X. et al. (2015). «Annual Healthcare Spending Attributable to Cigarette Smoking». *Am. J. Prev. Med.* — vía [ASH](#).
6. Cawley, J. & Meyerhoefer, C. (2012). «The medical care costs of obesity». *J. Health Econ.* — resumen en [systematic review](#).
7. scikit-learn: [Linear Models](#) · statsmodels: [Regression](#)