

Guía de aprendizaje: cómo hacer *realmente* este proyecto

Una ruta paso a paso, ordenada con la metodología CRISP-DM, para que un estudiante no experto —o una IA colaboradora— lleve el proyecto de principio a fin y cumpla cada criterio de evaluación.

Esta guía **integra** las Investigaciones 1 (herramientas) y 2 (técnicas y fórmulas) en un plan de acción. No repite las fórmulas; las *usa*.

1. ¿Qué vas a construir y qué debes saber antes?

Objetivo del proyecto: identificar qué hábitos de vida y factores demográficos se asocian con mayores gastos médicos, usando el dataset *Medical Cost Personal*, y comunicarlo con rigor.

Requisitos mínimos: nociones básicas de Python, saber abrir una terminal, y haber leído la Investigación 1 (para instalar el entorno) y la 2 (para entender correlación y regresión). No necesitas ser experto: la metodología te lleva de la mano.

2. El problema real y por qué importa

Una aseguradora quiere **fijar primas justas**: cobrar acorde al riesgo real de cada persona. Para eso necesita saber qué factores elevan el gasto. La pregunta de investigación:

«¿Qué variables (*edad, sexo, IMC, hijos, fumar, región*) se asocian con cargos médicos más altos, y cuánto pesa cada una?»

- **Variable dependiente (Y):** charges — el gasto médico en USD (lo que queremos explicar).
- **Variables independientes (X):** age, sex, bmi, children, smoker, region (los posibles factores).

Respaldo científico (verificado). La evidencia revisada por pares confirma que fumar (~11.7% del gasto sanitario de EE.UU.) y la obesidad (+\$1 861–2 505/adulto/año) elevan sustancialmente los costos. Esto le da sentido de mundo real al análisis.

Aviso de integridad. El dataset es **simulado** por Brett Lantz (basado en demografía del Census de EE.UU.), no son pacientes reales. El proyecto es un *ejercicio didáctico*: las técnicas son reales y transferibles; las cifras exactas, no clínicas. Declararlo demuestra madurez analítica.

3. La metodología: CRISP-DM

Para no trabajar «a lo loco», seguimos **CRISP-DM** (Cross-Industry Standard Process for Data Mining), el proceso estándar de la industria publicado por Chapman et al. (2000). Son **6 fases**, y el proyecto encaja casi 1 a 1 con ellas.

Fase CRISP-DM	Sección del entregable
1. Comprensión del negocio	Problemática a resolver
2. Comprensión de los datos	Descripción de los datos + EDA inicial
3. Preparación de los datos	Limpieza y codificación
4. Modelado	Análisis (regresión, correlación)
5. Evaluación	Interpretación de resultados
6. Despliegue	Conclusiones, recomendaciones, informe y presentación

Nota: el temario también menciona **SEMMA** (de SAS): Sample, Explore, Modify, Model, Assess. Es una alternativa muy parecida, más centrada en el modelado; CRISP-DM es más completo porque incluye negocio y despliegue.

4. Manos a la obra: paso a paso por fase

FASE 1 · Comprensión del negocio

Redacta con claridad: (a) el problema, (b) la pregunta, (c) las variables Y y X. Ya está avanzado

en el documento del equipo. **Entregable:** sección «Problemática a resolver».

FASE 2 · Comprensión de los datos

```
import pandas as pd
df = pd.read_csv("data/insurance.csv")
df.head(); df.info(); df.describe(include="all")
```

Describe la fuente (Kaggle / Lantz), el tamaño (1 338 registros, 7 variables) y el tipo de cada variable. Haz un EDA inicial: histograma de charges, conteos de smoker y region. **Objetivo:** conocer los datos y detectar anomalías. **Entregable:** «Descripción de los datos».

FASE 3 · Preparación de los datos

```
df = df.drop_duplicates() # quita 1 duplicado -> 1337 filas
df["sex"] = df["sex"].map({"male":0, "female":1})
df["smoker"] = df["smoker"].map({"no":0, "yes":1})
df = pd.get_dummies(df, columns=["region"], drop_first=True) # evita la
trampa dummy
```

Verifica nulos (`df.isnull().sum()` → 0) y duplicados antes y después. Documenta cada decisión: «se eliminó 1 duplicado para no sesgar el análisis». La rúbrica premia la **calidad** de esta limpieza (20%).

FASE 4 · Modelado

Dos técnicas complementarias (ver fórmulas en la Investigación 2):

1. **Correlación** (Pearson y Spearman) + mapa de calor → identifica que smoker domina ($r \approx 0.79$).
2. **Regresión lineal múltiple** → cuantifica el efecto de cada variable en dólares.

```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error
import numpy as np

X = df.drop(columns="charges"); y = df["charges"]
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.2, random_state=42)
```

```
modelo = LinearRegression().fit(Xtr, ytr)
pred = modelo.predict(Xte)
print("R2:", r2_score(yte, pred))
print("RMSE:", np.sqrt(mean_squared_error(yte, pred)))
print("MAE:", mean_absolute_error(yte, pred))
```

Justifica por qué regresión lineal: la variable objetivo es numérica y continua, y buscamos explicar/predecir su valor a partir de varios factores (justo el caso de uso de la regresión).

FASE 5 · Evaluación

Interpreta los números, no solo los reportes:

- **$R^2 \approx 0.75$** $\Rightarrow$ el modelo explica $\sim 75\%$ de la variación del gasto. Bueno para un modelo lineal simple.
- **Coefficiente de smoker $\approx +\$23\ 000$** $\Rightarrow$ a igualdad de lo demás, fumar se asocia con $\sim \$23\ 000$ más al año.
- Compara **RMSE vs MAE**: si $RMSE \gg MAE$, hay errores grandes puntuales por el sesgo de charges.
- Menciona **limitaciones**: posible heterocedasticidad; mejora con $\log(\text{charges})$; correlación $\neq$ causalidad; datos simulados.

Este es el criterio de **Interpretación (20%)**. Lo que distingue un 10 de un 7 es *conectar los números con el problema* y reconocer límites, no solo pegar la salida de la consola.

FASE 6 · Despliegue (comunicación)

Aquí «despliegas» los hallazgos como productos:

- **Conclusiones**: el tabaquismo es el factor dominante; IMC y edad importan de forma secundaria; sexo y región casi no influyen.
- **Recomendaciones**: programas de cesación de tabaco; tarifas ajustadas por riesgo; segmentar por perfiles.
- **Informe PDF** (portada institucional, introducción, desarrollo, conclusión, referencias) y **presentación** (Canva/pptx) solo con resultados interpretados.

5. Checklist contra la rúbrica del profesor

Criterio	Peso	¿Qué revisar?
Selección y descripción de datos	20%	Fuente citada, tamaño, variables, justificación de la elección.
Preparación de los datos	20%	Nulos, duplicados, codificación; EDA claro con gráficas.
Análisis de datos	30%	Correlación + regresión, con justificación de las técnicas y pantallazos de código/resultados.
Interpretación de resultados	20%	Números explicados, conexión con el problema, limitaciones.
Presentación y comunicación	10%	Estructura clara, informe PDF + slides.

El 30% (Análisis) es el de mayor peso. Prioriza tener regresión + correlación bien hechas y *justificadas*. Ahí se gana o se pierde la calificación.

6. Cómo escribir la interpretación (plantilla)

Estructura cada hallazgo en 3 frases:

1. **Qué:** «La correlación de smoker con charges es +0.79.»
2. **Qué significa:** «Los fumadores gastan en promedio \$32 050 vs \$8 441 de los no fumadores (~3.8×).»
3. **Por qué / con qué límite:** «Coincide con la evidencia médica; pero es correlación, no prueba causal, y los datos son simulados.»

7. Si eres una IA colaborando en este proyecto

1. Lee las Investigaciones 1 y 2 de esta carpeta antes de codificar.

2. Sigue las 6 fases en orden; no saltes la preparación de datos.
3. Reporta métricas *en el conjunto de prueba*, nunca solo en entrenamiento.
4. Sé explícito con las limitaciones (sesgo, causalidad, datos simulados).
5. Genera el informe con `scripts/generate_document.py <archivo> pdf` y déjalo en `docs/generated_docs/`.

8. Para seguir aprendiendo

Recurso	Para qué
<i>An Introduction to Statistical Learning</i> (James et al.)	Regresión y evaluación, con intuición. PDF gratuito.
<i>Python Data Science Handbook</i> (VanderPlas)	pandas, NumPy, matplotlib en profundidad. Gratis en línea.
CRISP-DM 1.0 (Chapman et al., 2000)	La metodología completa, fase por fase.
Documentación de scikit-learn	Ejemplos ejecutables de regresión y métricas.

Referencias

1. Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS/The CRISP-DM consortium.
2. Wirth, R. & Hipp, J. (2000). «CRISP-DM: Towards a Standard Process Model for Data Mining». *Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery*.
3. Schröer, C., Kruse, F. & Gómez, J. M. (2021). «A Systematic Literature Review on Applying CRISP-DM». *Procedia Computer Science* 181. [enlace](#)
4. Lantz, B. (2019). *Machine Learning with R* (3ª ed.), Packt — origen del dataset. [Kaggle: Medical Cost Personal Dataset](#)
5. James, G. et al. (2021). *An Introduction to Statistical Learning*. [statlearning.com](#)
6. Xu, X. et al. (2015), gasto sanitario atribuible al tabaquismo — vía [ASH](#); Cawley & Meyerhoefer (2012), costos de obesidad — [review](#).