

Análisis Exploratorio de Datos (EDA)

Entregable: 01_eda.ipynb · Responsables: Diego, Yazmin, Juan Pablo · Punto de partida: 00_setup.ipynb.

Investigación de apoyo para ejecutar esta fase. Explica el *qué*, el *por qué* y el *cómo*, con las fórmulas y el código comentados, pensada para que la entiendan tanto una persona sin experiencia como una IA colaboradora. Fuentes científicas citadas en formato APA al final.

1. Objetivo de la fase

El **Análisis Exploratorio de Datos** (EDA, por sus siglas en inglés) es el proceso de «conocer» los datos antes de modelarlos: ver cómo se distribuye cada variable, detectar valores extraños y descubrir relaciones. Fue formalizado por el estadístico **John Tukey** (1977), quien propuso usar gráficas simples para dejar que los datos «hablen» antes de imponerles un modelo. En CRISP-DM esta fase es la *Comprensión de los datos* (Chapman et al., 2000).

Cableado / dependencias (léelo aunque no seas de esta fase).

- **Recibe de Día 1 (setup):** el DataFrame ya cargado y sin duplicados (1 337 filas, 0 nulos). Cárgalo con
`pd.read_csv("../data/insurance.csv").drop_duplicates().`
- **Entrega a Día 3 (correlación) y Día 5 (clustering):** el conocimiento de qué variables están sesgadas y dónde hay outliers. La decisión que tomes sobre outliers (conservarlos o no) **afecta directamente** la correlación (Día 3), la regresión (Día 4) y el clustering (Día 5). Documenta esa decisión con claridad.
- **Genera archivos:** guarda todas las gráficas en `reports/figures/` con `plt.savefig()`. El equipo del Documento PDF (Día 7) usará esas imágenes.

2. Detección de valores atípicos (outliers)

Un **outlier** es un valor mucho más grande o más pequeño que el resto. Importa porque puede

arrastrar la media y distorsionar modelos. El método estándar es la **regla del rango intercuartílico (IQR)** de Tukey.

RANGO INTERCUARTÍLICO Y VALLAS DE TUKEY

$$\text{IQR} = Q_3 - Q_1 \quad ; \quad \text{valla inferior} = Q_1 - 1.5 \cdot \text{IQR} \quad ; \quad \text{valla superior} = Q_3 + 1.5 \cdot \text{IQR}$$

En español: Q_1 (primer cuartil) es el valor que deja por debajo al 25% de los datos; Q_3 (tercer cuartil), al 75%. El IQR es el ancho del «bloque central» del 50% de los datos. Todo lo que caiga *más allá* de 1.5 veces ese ancho por arriba o por abajo se considera atípico. El factor **1.5** no es arbitrario: Tukey lo eligió porque, en una distribución normal, deja fuera solo ~0.7% de los datos (Tukey, 1977; los detalles del porqué se discuten en la literatura de EDA).

```
import seaborn as sns, matplotlib.pyplot as plt
sns.boxplot(x=df["bmi"]); plt.title("Outliers en IMC");
plt.savefig("../reports/figures/box_bmi.png", dpi=150, bbox_inches="tight");
plt.show()
sns.boxplot(x=df["charges"]); plt.title("Outliers en cargos");
plt.savefig("../reports/figures/box_charges.png", dpi=150, bbox_inches="tight");
plt.show()
```

Cómo leer un boxplot (diagrama de caja)

La **caja** va de Q_1 a Q_3 (el 50% central). La **línea dentro** es la mediana. Los **bigotes** se extienden hasta las vallas de Tukey. Los **puntos sueltos** más allá de los bigotes son los outliers. En charges verás varios puntos altos: son personas con gastos muy elevados.

Decisión recomendada. En este dataset los outliers de charges y bmi son **casos reales** (personas que de verdad gastan mucho o tienen IMC alto), no errores de captura. Por eso **se conservan:** eliminarlos borraría justo a los perfiles de mayor riesgo, que son el foco del proyecto. Documenta esta decisión en el notebook.

3. Distribución de variables numéricas (histogramas)

Un **histograma** muestra cuántos registros caen en cada rango de valores; revela la *forma* de la distribución.

```
for col in ["age", "bmi", "children", "charges"]:
    sns.histplot(df[col], kde=True)
    plt.title(f"Distribución de {col}")
    plt.savefig(f"../reports/figures/hist_{col}.png", dpi=150,
bbox_inches="tight"); plt.show()
print(df[["age", "bmi", "children", "charges"]].skew())    # asimetría numérica
```

Sesgo (asimetría) y por qué importa

Una distribución es **simétrica** si su forma es un «campana» equilibrada. Es **sesgada a la derecha** (asimetría positiva) si tiene una cola larga hacia los valores altos. El coeficiente de asimetría (*skewness*) lo cuantifica: ≈ 0 simétrica, >0 cola a la derecha, <0 cola a la izquierda.

Qué vas a observar (verificado): charges está **fuertemente sesgada a la derecha** (skew $\approx +1.5$): la mayoría gasta poco y unos pocos gastan muchísimo. bmi es casi simétrica; age es bastante plana (uniforme).

Conexión con la Fase Día 4 (regresión). El sesgo de charges tiene consecuencias: la regresión lineal supone errores de varianza constante (homocedasticidad), y una variable objetivo tan sesgada suele violar ese supuesto. Una mejora conocida es modelar **log(charges)**, que «desinfla» la cola y acerca la distribución a la normal (Feng et al., 2014; Field, 2018). Menciónaselo al equipo de regresión.

4. Distribución de variables categóricas (countplots)

Para variables de texto (categorías) se cuenta cuántos registros hay de cada una con un **gráfico de barras**.

```
for col in ["sex", "smoker", "region"]:
    sns.countplot(x=col, data=df); plt.title(f"Frecuencia de {col}")
    plt.savefig(f"../reports/figures/count_{col}.png", dpi=150,
bbox_inches="tight"); plt.show()
```

Qué vas a observar: sex está casi 50/50; region reparte $\sim 25\%$ cada una; smoker está **desbalanceada**: solo $\sim 20\%$ son fumadores (274 de 1 337). Ese desbalance es importante para interpretar por qué, pese a ser minoría, los fumadores mueven tanto el gasto promedio.

5. Relación visual entre variables (scatterplots)

Un **diagrama de dispersión** coloca un punto por persona y revela relaciones entre dos variables. Colorear por smoker (hue) anticipa el hallazgo central.

```
sns.scatterplot(x="age", y="charges", hue="smoker", data=df)
plt.title("Edad vs Cargos (color = fumador)");
plt.savefig("../reports/figures/scatter_age.png", dpi=150, bbox_inches="tight");
plt.show()
sns.scatterplot(x="bmi", y="charges", hue="smoker", data=df)
plt.title("IMC vs Cargos (color = fumador)");
plt.savefig("../reports/figures/scatter_bmi.png", dpi=150, bbox_inches="tight");
plt.show()
```

Cómo interpretar estas gráficas

- **Edad vs cargos:** verás tres «bandas» que suben con la edad. Los fumadores (un color) ocupan las bandas superiores → gastan más a cualquier edad.
- **IMC vs cargos:** aquí aparece una **interacción** clave: entre *no fumadores* el IMC casi no cambia el gasto; entre *fumadores*, a mayor IMC el gasto se dispara. Esta interacción explica por qué la correlación lineal simple de IMC parece débil aunque el IMC sí importa (para fumadores).

6. Buenas prácticas y errores comunes

Haz esto	Evita esto
Titular y etiquetar cada gráfica (title, ejes).	Gráficas sin contexto que nadie entiende después.
Documentar en Markdown qué se observa en cada celda.	Solo pegar gráficas sin interpretar.
Guardar todo en reports/figures/ con bbox_inches="tight".	Perder las imágenes que necesita el Día 7.
Justificar la decisión sobre outliers.	Borrar outliers «porque sí» y sesgar el análisis.

7. Checklist del entregable (01_eda.ipynb)

- ☐ Boxplots de bmi y charges + decisión sobre outliers documentada.
- ☐ Histogramas de age, bmi, children, charges + comentario de sesgo.
- ☐ Countplots de sex, smoker, region.
- ☐ Al menos 2 scatterplots (age y bmi vs charges) coloreados por smoker.
- ☐ Todas las figuras guardadas en reports/figures/.
- ☐ Cada celda documentada con Markdown.

Referencias (APA 7)

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Feng, C., Wang, H., Lu, N., Chen, T., He, H., Lu, Y., & Tu, X. M. (2014). Log-transformation and its implications for data analysis. *Shanghai Archives of Psychiatry*, 26(2), 105–109. <https://doi.org/10.3969/j.issn.1002-0829.2014.02.009>

Field, A. (2018). *Discovering statistics using IBM SPSS statistics* (5th ed.). SAGE Publications.

McKinney, W. (2017). *Python for data analysis: Data wrangling with pandas, NumPy, and IPython* (2nd ed.). O'Reilly Media.

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>