

Análisis de Correlación

Entregable: 02_correlacion.ipynb · Responsables: Guillermo, Emiliano · Punto de partida: sección de correlación de 00_setup.ipynb.

Investigación de apoyo para ejecutar esta fase, con fórmulas y código explicados para persona e IA. Referencias científicas en APA al final.

1. Objetivo de la fase

La **correlación** mide qué tan asociadas están dos variables numéricas, con un número entre -1 y $+1$. El objetivo es identificar *qué factores se relacionan más con los cargos médicos (charges)* y comunicarlo en palabras, no solo mostrar números.

Cableado / dependencias.

- **Recibe de Día 1 (setup):** el DataFrame `df_numerico` ya codificado (variables de texto convertidas a número) y el *heatmap* preliminar. Si no existe, se reconstruye con el bloque de código del setup (mapeo de `sex/smoker` y `get_dummies` de `region`).
- **Recibe de Día 2 (EDA):** la decisión sobre outliers y el hecho de que `charges` está sesgada (esto justifica reportar también Spearman, no solo Pearson).
- **Entrega a Día 4 (regresión):** la lista de variables más asociadas con `charges`. La correlación *sugiere* qué variables incluir; la regresión las *cuantifica*. También avisa de **multicolinealidad** (variables X muy correlacionadas entre sí), que puede afectar la regresión.
- **Entrega a Días 6 y 7:** el hallazgo principal (fumar domina) y el heatmap, que irá en el documento y la presentación.

2. Por qué hay que codificar antes de correlacionar

La correlación necesita **números**. Por eso el setup transformó las categorías: sex y smoker a 0/1, y region con *one-hot* (`get_dummies(..., drop_first=True)`). Se usa `drop_first=True` para evitar la «trampa de las variables dummy» (colinealidad perfecta al dejar todas las categorías + intercepto).

3. Coeficiente de Pearson (relación lineal)

COEFICIENTE DE CORRELACIÓN DE PEARSON (r)

$$r = [\Sigma (x_i - \bar{x})(y_i - \bar{y})] / \sqrt{ [\Sigma(x_i - \bar{x})^2 \cdot \Sigma(y_i - \bar{y})^2] }$$

En español: el numerador (covarianza) mide si x e y suben juntas; el denominador normaliza por la dispersión de cada una para que el resultado quede entre -1 y +1. Pearson mide relación **lineal**, supone datos ~normales y es **sensible a outliers** (Schober et al., 2018).

Escala de interpretación (guía práctica)

|r| aproximado **Fuerza de la asociación**

0.00 – 0.10 Despreciable

0.10 – 0.39 Débil

0.40 – 0.69 Moderada

0.70 – 0.89 Fuerte

0.90 – 1.00 Muy fuerte

Escala orientativa basada en Schober et al. (2018). No es una ley rígida: el contexto manda.

4. Coeficiente de Spearman (relación monótona)

Como charges está sesgada y tiene outliers, conviene reportar también **Spearman**, que trabaja con los *rangos* (posiciones ordenadas) y es más robusto.

COEFICIENTE DE SPEARMAN (ρ), sin empates

$$\rho = 1 - [6 \cdot \sum d_i^2] / [n \cdot (n^2 - 1)]$$

Donde d_i es la diferencia de rangos de cada observación. Si Pearson y Spearman difieren mucho, es señal de relación **no lineal** (justo el caso de IMC entre fumadores).

5. Código: matriz y mapa de calor

```
import seaborn as sns, matplotlib.pyplot as plt

corr_pearson = df_numerico.corr(method="pearson")
corr_spearman = df_numerico.corr(method="spearman")

plt.figure(figsize=(10, 8))
sns.heatmap(corr_pearson, annot=True, cmap="coolwarm", fmt=".2f", vmin=-1, vmax=1)
plt.title("Matriz de correlación de Pearson")
plt.savefig("../reports/figures/heatmap_pearson.png", dpi=150,
            bbox_inches="tight"); plt.show()

print(corr_pearson["charges"].sort_values(ascending=False)) # ranking vs charges
```

Cómo leer el mapa de calor (heatmap)

Cada celda es la correlación entre dos variables. El **color** codifica el valor: rojo intenso $\approx +1$ (suben juntas), azul intenso ≈ -1 (una sube, otra baja), blanco ≈ 0 (sin relación lineal). La **diagonal** siempre es 1 (cada variable consigo misma). Lee la *fila/columna de charges* para ver qué variable se le acerca más al rojo.

6. Resultado aplicado (verificado en el dataset)

Variable vs charges	Pearson r	Lectura
smoker (fumador)	+0.79	Fuerte — el factor dominante
age (edad)	+0.30	Débil-moderada
bmi (IMC)	+0.20	Débil de forma lineal

children	+0.07	Despreciable
sex (sexo)	-0.06	Despreciable

7. Comparación de grupos: boxplots y violin plots

El mapa de calor no funciona con categorías crudas. Para comparar charges entre grupos se usan **boxplots** o **violin plots**.

```
for col in ["smoker", "region", "sex"]:
    sns.boxplot(x=col, y="charges", data=df) # usa el df ORIGINAL con texto
    plt.title(f"Cargos por {col}")
    plt.savefig(f"..../reports/figures/box_charges_{col}.png", dpi=150,
                bbox_inches="tight"); plt.show()
```

Boxplot vs violin plot: el boxplot muestra mediana, cuartiles y outliers; el *violin plot* añade la *forma* de la distribución (dónde se concentran los datos). Para smoker, el violín de fumadores se ve «gordo» en valores altos.

Qué vas a observar: la caja de fumadores está muy por encima (mediana $\approx$ \$34 000 vs $\approx$ \$7 300 en no fumadores). Por region y sex las cajas casi se solapan $\rightarrow$ poca diferencia. Esto confirma numéricamente lo que dijo la correlación.

8. Advertencia científica imprescindible

Correlación $\neq$ causalidad. Que smoker y charges estén correlacionados no *prueba* por sí solo que fumar cause el gasto; lo sugiere fuertemente. La causalidad se sostiene aquí porque además existe **evidencia médica externa** (Xu et al., 2015). Redacta la conclusión con este matiz: «asociado con», no «causa», salvo que cites evidencia causal.

9. Checklist del entregable (02_correlacion.ipynb)

- ☐ Heatmap de correlación (Pearson) con buen formato, guardado en reports/figures/.
- ☐ Ranking de correlación con charges e interpretación **en texto**.
- ☐ Boxplots/violin de charges por smoker, region y sex.

- ☐ 1–2 párrafos de conclusión: variables más relevantes y por qué.
- ☐ (Recomendado) mención de Spearman y de la advertencia correlación≠causalidad.

Referencias (APA 7)

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Schober, P., Boer, C., & Schwarte, L. A. (2018). Correlation coefficients: Appropriate use and interpretation. *Anesthesia & Analgesia*, 126(5), 1763–1768. <https://doi.org/10.1213/ANE.0000000000002864>

Spearman, C. (1904). The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1), 72–101. <https://doi.org/10.2307/1412159>

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>

Xu, X., Bishop, E. E., Kennedy, S. M., Simpson, S. A., & Pechacek, T. F. (2015). Annual healthcare spending attributable to cigarette smoking: An update. *American Journal of Preventive Medicine*, 48(3), 326–333. <https://doi.org/10.1016/j.amepre.2014.10.012>