

Regresión Lineal Múltiple (técnica principal)

Entregable: 03_regresion.ipynb · Responsables: Patricio, Gerardo · Punto de partida: df_numerico ya codificado.

Esta es la técnica que más peso tiene en la rúbrica (Análisis = 30%). Investigación de apoyo con fórmulas y código explicados. Referencias APA al final.

1. Objetivo de la fase

La **regresión lineal múltiple** construye una ecuación que estima el gasto médico (charges) a partir de varias variables a la vez, y —lo más importante para el proyecto— **cuantifica cuánto pesa cada factor en dólares**. Responde: «manteniendo lo demás igual, ¿cuánto sube el gasto por ser fumador, por cada año de edad, por cada punto de IMC?».

Cableado / dependencias.

- **Recibe de Días 1–3:** el df_numerico completo y codificado, con las columnas age, sex, bmi, children, smoker, region_northwest, region_southeast, region_southwest. Estas 3 columnas de región vienen de get_dummies(drop_first=True) (la región omitida, *northeast*, es la categoría de referencia).
- **Recibe de Día 2 (EDA):** el aviso de que charges está sesgada → considera reportar también un modelo con $\log(\text{charges})$ como mejora.
- **Recibe de Día 3 (correlación):** qué variables se asocian más con charges (esperado: smoker domina).
- **Entrega a Días 6 y 7:** R^2 , coeficientes y p-values, además de los *pantallazos* del resumen del modelo (el profesor los pide explícitamente).

2. El modelo y cómo se ajusta

MODELO DE REGRESIÓN LINEAL MÚLTIPLE

$$\hat{y} = \beta_0 + \beta_1 \cdot \text{age} + \beta_2 \cdot \text{sex} + \beta_3 \cdot \text{bmi} + \beta_4 \cdot \text{children} + \beta_5 \cdot \text{smoker} + \dots + \varepsilon$$

$\hat{y}$ es el gasto *predicho*; β_0 el intercepto; cada β_j dice cuánto cambia el gasto por una unidad de esa variable, con las demás constantes; ε es el error (lo que el modelo no explica). Los coeficientes se eligen por **mínimos cuadrados ordinarios (OLS)**: minimizan la suma de los errores al cuadrado.

CRITERIO OLS · SOLUCIÓN MATRICIAL

$$\min \sum (y_i - \hat{y}_i)^2 \rightarrow \beta = (X^T X)^{-1} X^T y$$

La fórmula matricial da los coeficientes de golpe: X es la tabla de datos (con una columna de unos para el intercepto), y el vector de gastos. No necesitas calcularla a mano: `statsmodels` lo hace.

3. Código explicado (statsmodels, recomendado)

Se recomienda `statsmodels` porque su `summary()` entrega **R², coeficientes y p-values** juntos — justo lo que pide el profesor.

```
import statsmodels.api as sm

# 1) Separar variables independientes (X) y dependiente (y)
X = df_numerico.drop(columns="charges")    # age, sex, bmi, children, smoker,
region_*
y = df_numerico["charges"]

# 2) Agregar la columna de intercepto (la constante β₀)
X = sm.add_constant(X)

# 3) Ajustar el modelo OLS y ver el resumen
modelo = sm.OLS(y, X).fit()
print(modelo.summary())
```

Línea por línea: `drop(columns="charges")` deja solo las X; `add_constant` agrega el término

β_0 (sin él, la recta pasaría forzada por el origen); `OLS(y, X).fit()` resuelve los mínimos cuadrados; `summary()` imprime la tabla que hay que interpretar y capturar en pantalla.

Alternativa scikit-learn (para predecir y medir error en datos nuevos):

`LinearRegression().fit(X_train, y_train) + r2_score, mean_squared_error.`

Lo ideal es **usar ambas**: statsmodels para interpretar, sklearn con `train_test_split` para evaluar honestamente en datos no vistos.

4. Cómo leer el resumen del modelo (lo que hay que capturar)

4.1 R^2 — ¿qué tan bueno es el modelo?

COEFICIENTE DE DETERMINACIÓN

$$R^2 = 1 - [\Sigma (y_i - \hat{y}_i)^2] / [\Sigma (y_i - \bar{y})^2]$$

Proporción de la variación del gasto que el modelo explica (0 a 1). Usa el **R^2 ajustado** para comparar modelos, porque penaliza variables inútiles.

Resultado esperado (verificado con literatura): este modelo alcanza **$R^2 \approx 0.75\text{--}0.76$** — explica $\sim 3/4$ de la variabilidad del gasto (Lantz, 2019; estudios replicados sobre el mismo dataset).

4.2 Coeficientes — ¿cuánto pesa cada variable?

Cada coeficiente está en **dólares**. Ejemplo de lectura: si el coeficiente de age es ~ 256 , cada año adicional se asocia con $\sim \$256$ más de gasto, con lo demás constante.

Coeficiente estrella (verificado): el de smoker ronda **+\$23 800** (estudios reales reportan 23 848 y 23 811). Es decir: a igualdad de edad, IMC, etc., ser fumador se asocia con $\sim \$23\,800$ más de gasto anual. Es, con enorme diferencia, el mayor efecto.

4.3 P-values — ¿qué variables son significativas?

El **p-value** es la probabilidad de ver este efecto por puro azar si la variable en realidad no influyera. Regla estándar: **$p < 0.05$** — la variable es *estadísticamente significativa*. Ojo: significativo no es lo

mismo que «grande»; solo dice que el efecto probablemente no es casualidad.

Esperado: age, bmi y smoker salen muy significativas (p muy pequeña); sex y algunas region_* suelen no ser significativas ($p > 0.05$).

Malinterpretación común. Un p-value alto (>0.05) NO prueba que la variable «no sirve»; solo que *en estos datos* no hay evidencia suficiente de su efecto. No lo redactes como «no influye», sino como «no resultó estadísticamente significativa».

5. Supuestos y una mejora recomendada

OLS es óptimo (BLUE) si se cumplen los supuestos de Gauss-Markov: linealidad, independencia, no multicolinealidad perfecta, exogeneidad y **homocedasticidad** (varianza del error constante).

Mejora que suma puntos: por el sesgo de charges, es casi seguro que se viole la homocedasticidad. Ajusta un segundo modelo con $y = \text{np.log(df_numerico["charges"])$ y compara el R^2 . La transformación log estabiliza la varianza y suele mejorar el ajuste (Feng et al., 2014). Interpretar coeficientes en escala log cambia (pasan a ser ~% de cambio), así que explícalo.

6. Checklist del entregable (03_regresion.ipynb)

- ☐ Separación clara de X (8 columnas) e y (charges).
- ☐ Modelo OLS ajustado con statsmodels (o sklearn) + add_constant.
- ☐ Reporte y explicación de R^2 (y R^2 ajustado).
- ☐ Tabla de coeficientes interpretada en dólares.
- ☐ P-values: qué variables son significativas ($p < 0.05$) y cuáles no.
- ☐ **Pantallazos** del código y del resumen del modelo.
- ☐ Conclusión: qué tan bueno es el modelo y qué variables predicen mejor.
- ☐ (Recomendado) modelo alternativo con $\log(\text{charges})$.

Referencias (APA 7)

Feng, C., Wang, H., Lu, N., Chen, T., He, H., Lu, Y., & Tu, X. M. (2014). Log-transformation and its implications for data analysis. *Shanghai Archives of Psychiatry*, 26(2), 105–109. <https://doi.org/10.3969/j.issn.1002-0829.2014.02.009>

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>

Lantz, B. (2019). *Machine learning with R* (3rd ed.). Packt Publishing.

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to linear regression analysis* (6th ed.). Wiley.

Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92–96. <https://doi.org/10.25080/Majora-92bf1922-011>