

Análisis de Clusters con K-means

Entregable: 04_clustering.ipynb · Responsables: José Antonio, Ángel · Punto de partida: dataset limpio del Día 1.

Investigación de apoyo con fórmulas, código e interpretación explicados para persona e IA. Referencias APA al final.

1. Objetivo de la fase

El **clustering** (agrupamiento) es *aprendizaje no supervisado*: no hay una «respuesta correcta» que predecir; el algoritmo busca **grupos naturales** de asegurados parecidos entre sí. Objetivo del proyecto: descubrir **perfiles de riesgo** (p. ej., «jóvenes de bajo costo» vs «IMC alto y costo elevado»). Usaremos **K-means**, propuesto por MacQueen (1967) y Lloyd (1982).

Cableado / dependencias.

- **Recibe de Día 1 (setup):** el dataset limpio. Aquí NO se usa el `df_numerico` con dummies de la regresión, sino las variables numéricas crudas `age`, `bmi`, `charges` (las sugeridas por el plan).
- **Recibe de Día 2 (EDA):** el conocimiento de las escalas tan distintas de `age` (18–64), `bmi` (16–53) y `charges` (1 000–64 000) → por eso **hay que escalar** (ver §3).
- **Es independiente de la regresión (Día 4):** son técnicas paralelas. La regresión *explica/predice*; el clustering *segmenta*. Se complementan en la interpretación final (Día 6).
- **Entrega a Días 6 y 7:** los perfiles de cada cluster y el scatter coloreado por grupo, que van al documento y la presentación.

2. Cómo funciona K-means (idea + fórmula)

K-means divide los datos en **K** grupos. Cada grupo tiene un **centroide** (su punto central). El algoritmo repite dos pasos hasta estabilizarse (Lloyd, 1982):

1. **Asignación:** cada punto se une al centroide más cercano (distancia euclidiana).
2. **Actualización:** cada centroide se recalcula como el promedio de sus puntos.

El objetivo que minimiza es la **inercia** o suma de cuadrados intra-cluster (WCSS):

INERCIA / WCSS (lo que K-means minimiza)

$$WCSS = \sum_{k=1..K} \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

En español: para cada cluster C_k con centroide μ_k , se suman las distancias al cuadrado de sus puntos al centro; luego se suma sobre todos los clusters. Cuanto menor es la inercia, más «apretados» están los grupos. La distancia euclidiana entre dos puntos es $\sqrt{\sum (a_i - b_i)^2}$.

3. Paso obligatorio: escalar los datos (StandardScaler)

¡No te saltes esto! K-means usa distancias euclidianas. Si no se escala, charges (que llega a 64 000) **dominaría** por completo a age (máx 64) y bmi (máx 53): el clustering agruparía prácticamente solo por gasto. Escalar pone a todas las variables en igualdad de condiciones (IBM, s.f.; documentación de scikit-learn).

ESTANDARIZACIÓN Z-SCORE (StandardScaler)

$$z = (x - \mu) / \sigma$$

En español: a cada valor se le resta la media (μ) de su columna y se divide entre su desviación estándar (σ). El resultado: cada variable queda con **media 0 y desviación 1**, sin unidades, comparables entre sí.

4. Elegir K: el método del codo (elbow)

¿Cuántos grupos? El **método del codo** (Thorndike, 1953) prueba varios valores de K y grafica la inercia. Al aumentar K la inercia siempre baja; se busca el «**codo**»: el punto donde bajar más deja de aportar mucho.

```

from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

X = df[["age", "bmi", "charges"]]
X_scaled = StandardScaler().fit_transform(X)      # media 0, desv 1

inercias = []
for k in range(1, 11):
    km = KMeans(n_clusters=k, random_state=42, n_init=10).fit(X_scaled)
    inercias.append(km.inertia_)
plt.plot(range(1, 11), inercias, marker="o")
plt.xlabel("Número de clusters (K)"); plt.ylabel("Inercia (WCSS)")
plt.title("Método del codo"); plt.savefig("../reports/figures/codo.png", dpi=150,
bbox_inches="tight"); plt.show()

```

Cómo leer la gráfica del codo

Es una curva descendente. Busca dónde el descenso «se dobla» formando un ángulo, como un codo. Ese K es el elegido. Para estas variables suele salir **K = 3 o 4**.

Valida con la silueta (más fiable). El codo a veces no es claro. El **coeficiente de silueta** (Rousseeuw, 1987) va de -1 a $+1$ y mide qué tan bien separado está cada punto de su grupo respecto a los vecinos; se elige el K con mayor silueta promedio. Si codo y silueta discrepan, se prefiere la silueta.

```

from sklearn.metrics import silhouette_score

for k in range(2, 7):

    lab = KMeans(n_clusters=k, random_state=42,
n_init=10).fit_predict(X_scaled)

    print(k, silhouette_score(X_scaled, lab))

```

5. Aplicar K-means y visualizar

```

k_opt = 3      # el que indique el codo/silueta
km = KMeans(n_clusters=k_opt, random_state=42, n_init=10)
df["cluster"] = km.fit_predict(X_scaled)      # etiqueta de grupo por persona

```

```
import seaborn as sns
sns.scatterplot(x="bmi", y="charges", hue="cluster", palette="Set1", data=df)
plt.title("Clusters de asegurados (IMC vs Cargos)")
plt.savefig("../reports/figures/clusters.png", dpi=150, bbox_inches="tight");
plt.show()

print(df.groupby("cluster")[["age", "bmi", "charges"]].mean()) # perfil de cada grupo
```

Detalles del código: `random_state=42` hace el resultado reproducible; `n_init=10` corre el algoritmo 10 veces con distintos inicios y se queda con el mejor (K-means depende del punto de partida). Se grafica con las variables sin escalar para que los ejes sean interpretables (dólares, IMC), pero el *agrupamiento* se hizo con los datos escalados.

6. Interpretar los clusters (lo más importante)

Un cluster sin interpretar no vale. Usa `df.groupby("cluster").mean()` para leer el perfil promedio de cada grupo y **ponle nombre**. Ejemplo del tipo de resultado esperado:

Cluster	Perfil promedio	Nombre sugerido
0	Jóvenes, IMC normal, cargos bajos	Bajo riesgo
1	Edad media, IMC alto, cargos moderados-altos	Riesgo por IMC
2	Cargos muy elevados (suele coincidir con fumadores)	Alto riesgo / costo elevado

Los perfiles exactos dependen del K y de la corrida; describe los tuyos según lo que muestre tu `groupby`.

Limitaciones honestas (decláralas). (1) K-means asume grupos «esféricos» de tamaño similar y es sensible a outliers; con `charges` sesgada, un grupo puede quedar dominado por los gastos extremos. (2) El resultado depende de qué variables elijas y de la escala. (3) Los grupos son *estadísticos*, no categorías médicas oficiales. Menciónalo en la interpretación.

7. Checklist del entregable (04_clustering.ipynb)

- ☐ Selección de variables (age, bmi, charges) justificada.
- ☐ **Escalado** con `StandardScaler` antes de K-means.
- ☐ Método del codo graficado (y, recomendado, silueta).
- ☐ K-means aplicado con el K elegido.
- ☐ Scatter de clusters (bmi vs charges) coloreado por grupo, guardado en `reports/figures/`.
- ☐ Perfil de cada cluster con `groupby` + interpretación con nombres de riesgo.
- ☐ Limitaciones documentadas. Markdown en cada sección.

Referencias (APA 7)

IBM. (s.f.). *What is k-means clustering?* IBM Think. <https://www.ibm.com/think/topics/k-means-clustering>

Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129–137. <https://doi.org/10.1109/TIT.1982.1056489>

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. En *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* (Vol. 1, pp. 281–297). University of California Press.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)

Thorndike, R. L. (1953). Who belongs in the family? *Psychometrika*, 18(4), 267–276. <https://doi.org/10.1007/BF02289263>