

Interpretación y Conclusiones Consolidadas

Entregable: texto base de interpretación, limitaciones y recomendaciones · Responsables: Todo el equipo.

Investigación de apoyo para convertir cuatro notebooks en un mensaje claro y honesto. Referencias APA al final.

1. Objetivo de la fase

En CRISP-DM esta es la **Evaluación**: dejar de producir resultados y empezar a *darles sentido* en el contexto del problema. Se consolidan los hallazgos de los Días 2–5 en una narrativa única, se declaran las limitaciones y se redactan conclusiones y recomendaciones. Este texto es la **materia prima** del documento y la presentación del Día 7.

Cableado / dependencias.

- **Recibe de Día 2 (EDA)**: distribuciones, sesgo de charges, decisión sobre outliers.
- **Recibe de Día 3 (correlación)**: ranking de asociación (fumar domina).
- **Recibe de Día 4 (regresión)**: $R^2 \approx 0.75$ y coeficientes en dólares (fumar $\approx +\$23\,800$).
- **Recibe de Día 5 (clustering)**: perfiles de riesgo.
- **Entrega a Día 7**: conclusiones, limitaciones y recomendaciones ya redactadas.

2. Cómo consolidar: la estructura Hallazgo → Evidencia → Significado

Para cada conclusión, encadena tres piezas (evita el error de solo listar números):

Pieza	Ejemplo integrado
Hallazgo	Fumar es el factor más asociado con el gasto médico.

Evidencia (de varios notebooks) Correlación +0.79 (Día 3); coeficiente +\$23 800 con $p < 0.05$ (Día 4); el cluster de alto costo coincide con fumadores (Día 5).

Significado Un asegurado fumador implica un riesgo de costo mucho mayor; concuerda con la evidencia médica (Xu et al., 2015).

La fuerza de la triangulación. Que tres técnicas distintas (correlación, regresión y clustering) apunten al mismo factor hace la conclusión mucho más robusta que un solo número. Resáltalo.

3. Conclusiones esperadas (borrador base)

- **Tabaquismo:** factor dominante del gasto (asociación fuerte y significativa; ~+\$23 800).
- **Edad e IMC:** factores secundarios pero significativos; el IMC pesa sobre todo *combinado con fumar* (interacción vista en el EDA).
- **Sexo y región:** influencia débil o no significativa.
- **Perfiles de riesgo:** el clustering separa al menos un grupo de «alto costo» claramente diferenciado.

4. Limitaciones (declararlas SUMA puntos)

Un buen análisis reconoce sus límites (esto pesa en el criterio de Interpretación, 20%):

- **Datos simulados:** `insurance.csv` fue generado por Brett Lantz sobre demografía del Censo de EE.UU. (Lantz, 2019); no son pacientes reales. Las técnicas y tendencias son válidas y didácticas, pero las cifras no son clínicas.
- **Ámbito geográfico:** solo EE.UU.; no generaliza directo a México u otros países.
- **Variables ausentes:** no hay historial médico, enfermedades previas, ingreso, actividad física... que también afectan el gasto.
- **Correlación $\neq$ causalidad:** el estudio es observacional; identifica asociaciones, no causas probadas.

- **Supuestos del modelo:** el sesgo de charges puede violar la homocedasticidad (mitigable con $\log(\text{charges})$).

5. Recomendaciones (basadas en los hallazgos)

Deben derivarse de los datos y ser accionables para la aseguradora:

- **Primas ajustadas por riesgo** según condición de fumador (el factor de mayor impacto).
- **Programas de cesación de tabaco** y de control de IMC como estrategia para reducir costos a largo plazo (respaldado por evidencia de costos del tabaquismo y la obesidad; Xu et al., 2015; Cawley & Meyerhoefer, 2012).
- **Segmentación por perfiles** del clustering para diseñar productos diferenciados.
- **Recolectar más variables** (historial médico) en futuros análisis para mejorar la predicción.

6. Dinámica de la reunión (Día 6)

1. Cada dupla/trío presenta sus hallazgos (~5 min).
2. Se llena la tabla Hallazgo → Evidencia → Significado en conjunto.
3. Se acuerdan limitaciones y recomendaciones.
4. Se deja todo por escrito como base para el Día 7.

7. Checklist del entregable

- ☐ Conclusiones que integran los 4 notebooks (no listas sueltas).
- ☐ Limitaciones explícitas (mínimo las 5 de arriba).
- ☐ Recomendaciones accionables ligadas a los hallazgos.
- ☐ Documento base listo para el equipo del PDF y de la presentación.

Referencias (APA 7)

Cawley, J., & Meyerhoefer, C. (2012). The medical care costs of obesity: An instrumental variables approach. *Journal of Health Economics*, 31(1), 219–230. <https://doi.org/10.1016/j.jhealeco.2011.10.003>

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Lantz, B. (2019). *Machine learning with R* (3rd ed.). Packt Publishing.

Xu, X., Bishop, E. E., Kennedy, S. M., Simpson, S. A., & Pechacek, T. F. (2015). Annual healthcare spending attributable to cigarette smoking: An update. *American Journal of Preventive Medicine*, 48(3), 326–333.
<https://doi.org/10.1016/j.amepre.2014.10.012>